НАО «Казахский агротехнический исследовательский университет имени С. Сейфуллина»
Конкурс командных ИТ-проектов в области искусственного интеллекта «AI autumn»

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

EginAI

Интеллектуальная система раннего выявления болезней пшеницы по фотографии

Направление: Агротех, экология и умный город

Команда: Әбдімүтәлі Бекназар (капитан), Әбдіқадыр Ернұр, Есен Арман, Жақсығұл Рамазан

Научный руководитель: Таберхан Роман

Астана, 2026

Содержание

Аннотация.....
1. Проблема и актуальность.....
2. Цель и задачи.....
3. Анализ аналогов и отличия.....
4. Описание решения.....
   4.1. Функционал.....
   4.2. Архитектура.....
5. Используемые технологии.....
6. Данные и обучение модели.....
7. Результаты и тестирование.....
   7.1. Качество модели.....
   7.2. Производительность.....
   7.3. Автоматические тесты.....
   7.4. Ручное тестирование.....
8. Безопасность, законность и этика.....
9. Ограничения и перспективы развития.....
10. Команда и распределение работ.....
Список источников.....

Аннотация

EginAI — веб-приложение и Telegram-бот, которые по фотографии листа или колоса пшеницы за доли секунды определяют болезнь, показывают, на какие участки снимка опиралась нейросеть, и выдают рекомендации по защите посевов на казахском и русском языках. С согласия пользователя случай отмечается на публичной карте очагов, что позволяет агрономам и соседним хозяйствам заметить распространение болезни раньше.

Ядро системы — свёрточная нейросеть EfficientNet-B0, дообученная на открытом полевом датасете из 4156 фотографий пшеницы (лицензия CC-BY-4.0). Модель различает 7 классов: бурую и жёлтую ржавчину, мучнистую росу, фузариоз колоса, септориоз колоса, здоровый лист и здоровый колос. На отложенной тестовой выборке (**580 изображений**) достигнуты **точность 97,1 % и macro-F1 96,7 %**; обработка одного снимка на обычном процессоре занимает около 57 мс. Система запускается одной командой docker compose up и полностью работает без внешних API-ключей.

Ключевые слова: компьютерное зрение, болезни пшеницы, transfer learning, EfficientNet, CAM, RAG, AgroTech, Казахстан.

1. Проблема и актуальность

Казахстан — один из крупнейших производителей и экспортёров пшеницы в регионе; зерновое хозяйство является основой агропромышленного комплекса Северного и Центрального Казахстана. По оценкам ФАО, вредители и болезни ежегодно уничтожают до 40 % мирового урожая продовольственных культур [1]. Для яровой пшеницы северных областей наибольшую угрозу представляют листовые болезни — бурая ржавчина, септориоз, мучнистая роса, а в годы с прохладной весной — жёлтая ржавчина [2, 3].

Болезни часто замечают слишком поздно. Визуальная диагностика требует опыта, а квалифицированных агрономов в отдалённых сёлах не хватает. Поздняя или неточная диагностика приводит к двум потерям: недобору урожая и лишним затратам на фунгициды, которые вносят «на всякий случай». Кроме того, у фермера нет простого способа узнать, что болезнь уже появилась у соседей.

Целевая аудитория: фермеры и небольшие хозяйства (основные пользователи), агрономы хозяйств, районные фитосанитарные службы и акиматы (пользователи карты очагов), студенты и преподаватели аграрных вузов.

Проект соответствует курсу на цифровизацию АПК и развитие технологий искусственного интеллекта в Республике Казахстан.

2. Цель и задачи

Цель: создать доступный инструмент, с помощью которого фермер по одной фотографии за несколько секунд определяет болезнь пшеницы и получает понятные рекомендации на родном языке.

Задачи:

1. Собрать и подготовить размеченный датасет болезней пшеницы, снятых в полевых условиях.
2. Обучить и проверить на отложенной выборке классификатор с точностью не ниже 90 %.
3. Сделать результат объяснимым: показывать зону признаков и честно сообщать о неуверенности модели.
4. Подготовить базу агрономических знаний на казахском и русском языках и механизм ответов на вопросы по ней (RAG).
5. Реализовать два канала доступа — мобильное веб-приложение и Telegram-бот — и карту очагов с соблюдением законодательства о персональных данных.
6. Обеспечить запуск у жюри без доработок и без платных сервисов.

3. Анализ аналогов и отличия

Мы изучили существующие решения по магазинам приложений и открытым источникам, а также прочитали 77 публичных отзывов пользователей Plantix, Agrio и Farmonaut (Google Play и App Store), чтобы понять, чем недовольны фермеры [4]. Сводная таблица приведена ниже.

Таблица 1 — Сравнение с аналогами (данные на 12.11.2026)

Решение	**Языки**	**Пшеница / ячмень KZ**	**Карта очагов**	**Чем отличается EginAI**
Plantix (Германия)	19 языков, есть RU; KK нет	Пшеница — да; ячменя нет	Нет, push «в вашем районе»	Казахский язык; Telegram; без рекламы; публичная карта по районам
Agrio (Израиль)	EN	Зерновые не заявлены	Нет	Бесплатно без рекламы; честный отказ при низкой уверенности
PlantVillage Nuru (США)	EN, FR, HI, SW, TW	Ржавчина — в разработке (Эфиопия)	Нет	KK/RU; болезни зерновых Северного Казахстана
Farmonaut (Индия)	EN	Нет фото-диагностики листа	Карта своих полей (NDVI)	Диагноз по фото за секунды без подписки
DoctorP (РФ)	EN, RU	Пшеница — да	Нет	Казахский язык; Telegram; карта очагов
Проекты РК (Павлодар, Agroscope)	нет приложения	Исследования, спутник/дроны	Нет	Готовый сервис для телефона

Главные жалобы пользователей аналогов: ИИ «не знает» болезнь или уверенно ошибается (16 отзывов), реклама и платные подписки (11), нужной культуры нет в списке (8), «спросите эксперта» без ответа (5). Ни одно найденное решение не поддерживает казахский язык и не ведёт открытую карту очагов. Отсюда отличия EginAI:

- **Казахский язык по умолчанию** и русский.
- **Узкий фокус** на болезнях пшеницы, важных для Северного Казахстана, вместо «доктора для всех растений».

- **Честная неопределённость:** топ-3 вариантов с вероятностями, тепловая карта признаков и ответ «переснимите», если уверенность низкая или на фото не растение.
- **Без рекламы, регистрации и установки:** работает в браузере и в Telegram.
- **Публичная карта очагов** с точностью ~1 км и только с согласия пользователя.

4. Описание решения

4.1. Функционал

- **Диагностика по фото.** Пользователь снимает лист или колос камерой телефона или выбирает фото из галереи. Снимок уменьшается на устройстве до 1600 px и отправляется на сервер.
- **Результат.** Название болезни, возбудитель, уровень опасности, уверенность модели, оценка доли поражённой площади и два альтернативных варианта.
- **Объяснимость.** Переключатель «Оригинал / Зона признаков» показывает тепловую карту CAM — участки, по которым модель приняла решение.
- **Рекомендации.** Признаки, условия распространения, порог вредоносности, агротехнические и химические меры (по группам действующих веществ, без брендов и доз — со ссылкой на Список пестицидов РК), сроки обработки, профилактика, как отличить от похожих болезней, источники.
- **Вопрос агроному.** Свободный вопрос на казахском или русском; ответ формируется из базы знаний с учётом поставленного диагноза.
- **Карта очагов.** С согласия пользователя случай (болезнь, дата, место, округлённое до ~1 км) попадает на карту; фильтры по болезни и периоду.
- **Telegram-бот** с теми же функциями: фото → диагноз с тепловой картой → совет → «Отметить на карте» через отправку геолокации.

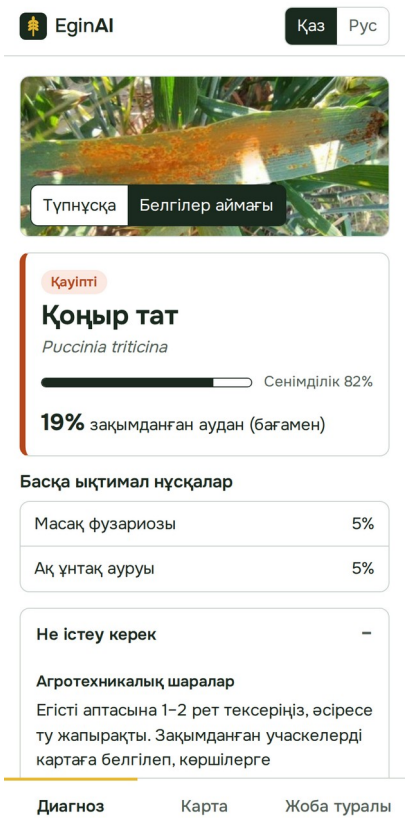


Рисунок 1 — Результат диагностики (казахский интерфейс)

4.2. Архитектура

Система состоит из трёх частей: офлайн-конвейера обучения, сервера API и клиентов (веб и бот). Сервер FastAPI выполняет инференс модели в формате ONNX на процессоре, обращается к базе знаний и сохраняет только согласованные случаи в PostgreSQL. Веб-приложение собирается в статические файлы и раздаётся тем же сервером, поэтому для запуска достаточно двух контейнеров (API и БД); бот — опциональный третий.

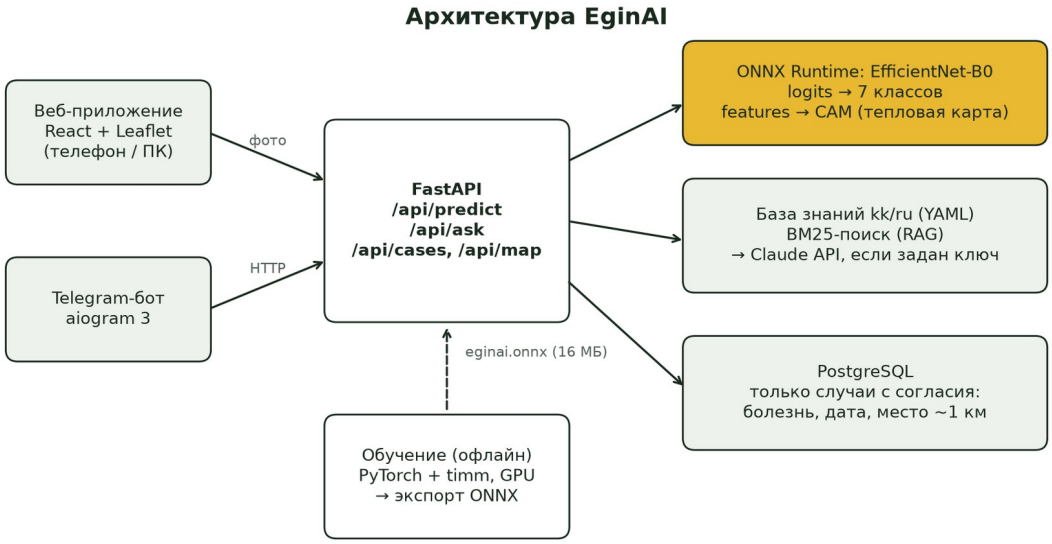


Рисунок 2 — Архитектура EginAI

Объяснимость без градиентов. Классификатор EfficientNet-B0 заканчивается глобальным усреднением и линейным слоем, поэтому карта активации класса с

вычисляется точно как CAM = ReLU(Σ_k $W_{k,c}$ · F_k) [5]. Модель экспортируется в ONNX с двумя выходами — logits и картой признаков 1280×7×7, — и сервер строит тепловую карту обычным умножением матриц, без PyTorch. При экспорте автоматически проверяется, что avgpool(F)·W^T + b совпадает с logits.

Проверка «это вообще растение?». Перед выдачей диагноза оценивается доля пикселей жёлто-зелёно-бурых оттенков с достаточной насыщенностью. Серый, белый или синий кадр (стена, лист бумаги, небо) получает ответ «на фото не видно растения». При максимальной вероятности ниже 0,5 система сообщает о неуверенности и показывает варианты.

База знаний и RAG. Для каждого класса подготовлены тексты на двух языках (признаки, условия, порог, меры, сроки, профилактика, дифференциация). Вопрос пользователя разбивается на основы слов (4 символа для казахского, 5 для русского — учёт агглютинации без морфоанализатора), BM25 находит ближайшие фрагменты, при известном диагнозе приоритет получает соответствующая болезнь. Если задан ключ Claude API, языковая модель формулирует ответ строго по найденным фрагментам; без ключа или при ошибке API возвращаются сами фрагменты.

5. Используемые технологии

Таблица 2 — Технологический стек

Слой	Технологии
Машинное обучение	Python 3.12, PyTorch 2.11, timm (EfficientNet-B0, веса ImageNet), torchvision transforms, scikit-learn (метрики)
Инференс	ONNX, ONNX Runtime (CPU), NumPy, Pillow
Backend	FastAPI, Uvicorn, SQLAlchemy 2, PostgreSQL 16, PyYAML, rank-bm25, Anthropic SDK (опционально)
Telegram-бот	aiogram 3, httpx
Frontend	React 19, TypeScript, Vite, Leaflet + OpenStreetMap, шрифт Onest (проверено наличие всех букв казахского алфавита)
Инфраструктура	Docker, Docker Compose, Git/GitHub, pytest (52 автотеста), Playwright (скриншоты и запись демо)

Все сторонние компоненты и их лицензии перечислены в файле THIRD_PARTY.md репозитория; собственный код распространяется по лицензии MIT.

6. Данные и обучение модели

Использован открытый датасет Project-AgML/wheat_disease_detection [6]: 4156 полевых фотографий пшеницы (Хэнаньский аграрный университет, 2023 г.), снятых смартфоном и фотоаппаратом при естественном освещении, с 7 классами и рамками (bounding boxes) поражённых участков. Датасет предназначен для детекции; мы преобразовали его в классификационный — каждая рамка вырезается с запасом 25 % (не менее 64 px) и попадает в папку своего класса. Разбиение train/val/test взято из

датасета и сделано по изображениям, поэтому фрагменты одного снимка не могут оказаться одновременно в обучении и в тесте.

Таблица 3 — Распределение фрагментов по классам

Класс	Train	Val	Test
Фузариоз колоса	1060	110	125
Септориоз колоса	351	41	36
Здоровый колос	491	52	81
Здоровый лист	680	103	66
Бурая ржавчина	827	102	107
Мучнистая роса	810	108	102
Жёлтая ржавчина	470	60	63
Всего	4689	576	580

Обучение: EfficientNet-B0 с весами ImageNet, вход 224×224, AdamW (lr $4 \cdot 10^{-4}$, weight decay 0,02), OneCycle, сглаживание меток 0,1, dropout 0,3, сбалансированная выборка редких классов, смешанная точность (AMP). Аугментации имитируют полевую съёмку: случайное кадрирование 50–100 %, отражения, поворот ±20°, изменение яркости, контраста и насыщенности. 15 эпох на GPU GeForce GTX 1650 (4 ГБ) заняли около 15 минут; лучшая модель выбрана по macro-F1 на валидации (0,962).

7. Результаты и тестирование

7.1. Качество модели

Оценка выполнена на отложенной тестовой выборке тем же кодом и той же ONNX-моделью, что работают в приложении. **Accuracy — 97,1 %, macro-F1 — 96,7 %.** Цель из заявки (не ниже 90 %) достигнута.

Таблица 4 — Метрики по классам на тестовой выборке

Класс	Precision	Recall	F1	Изображений
Фузариоз колоса	0.99	0.98	0.99	125
Септориоз колоса	0.88	0.97	0.92	36
Здоровый колос	0.97	0.95	0.96	81
Здоровый лист	0.96	0.98	0.97	66
Бурая ржавчина	0.97	0.97	0.97	107
Мучнистая роса	0.97	0.94	0.96	102
Жёлтая ржавчина	1.00	1.00	1.00	63

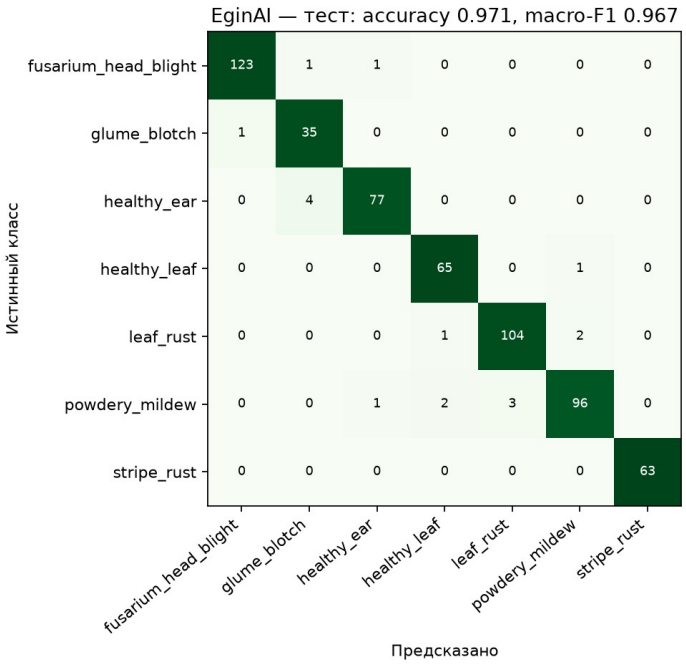


Рисунок 3 — Матрица ошибок на тестовой выборке

Наибольшая путаница — между септориозом колоса и здоровым колосом (4 случая) и между мучнистой росой и бурой ржавчиной (3 случая): это ранние стадии с небольшими пятнами. Важно, что модель сама сообщает о неуверенности: из 580 тестовых снимков 12 получили ответ «модель сомневается», и среди уверенных ответов точность составила 98,4 %. Проверка «не растение» ошибочно отклонила 1 из 580 реальных снимков.



Рисунок 4 — Тепловые карты CAM: модель смотрит на пустулы ржавчины и налёт мучнистой росы

7.2. Производительность

Медианное время обработки одного снимка на процессоре — 57 мс; с построением тепловой карты и сетью — около 0,1–0,3 с, что значительно лучше требования заявки (не более 5 с). Изображение 8000×6000 обрабатывается менее чем за 5 с (покрыто автотестом). Размер модели — 16 МБ.

7.3. Автоматические тесты

Репозиторий содержит 52 автотеста (pytest): подготовка данных (6), диагностика и API (12), карта и база данных (8), база знаний и поиск (21), тексты бота (5). Проверяются в том числе: повреждённый файл → 422, не изображение → 415, файл больше 10 МБ → 413, сообщения об ошибках на выбранном языке, неуверенный ответ на серое, синее, белое, однотонное и 1×1 изображение, ответ 422 вместо 500 на NaN, отсутствие сохранения при отказе от согласия, округление координат, работа диагностики при недоступной базе данных (карта отвечает 503), откат к базе знаний при ошибке языковой модели.

7.4. Ручное тестирование

Сквозные сценарии (фото → диагноз → совет → вопрос → отметка на карте; переключение языка; карта с фильтрами) проверены в браузере в мобильном разрешении 412×860 и записаны в демонстрационное видео. Сборка docker compose проверена с нуля: стек поднимается, проходит health-check и отвечает на все маршруты.

8. Безопасность, законность и этика

- Пароли и ключи в коде отсутствуют; конфигурация — через переменные окружения (.env не попадает в git, в репозитории только .env.example).
- Фотографии не сохраняются ни на диск, ни в базу. На карту записываются только болезнь, дата и координаты, округлённые до двух знаков (~1 км), и только после явного согласия. Регистрация, имя и телефон не запрашиваются. Это соответствует принципу минимизации данных Закона РК «О персональных данных и их защите».
- Защита от некорректного ввода: ограничение размера файла, защита от «бомб декомпрессии», ограничение числа запросов с одного IP, защита от выхода за пределы каталога при раздаче статики, контейнер работает от непривилегированного пользователя.
- Авторские права: датасет CC-BY-4.0 с указанием авторов, веса модели Apache-2.0, все библиотеки — с перечнем лицензий. Тексты базы знаний написаны командой по открытым справочникам.
- Этика рекомендаций: система не называет торговые марки и дозы, а указывает группы действующих веществ и отсылает к официальному Списку пестицидов РК и агроному. Ограничения модели (только пшеница, данные другого региона) открыто описаны в интерфейсе.

9. Ограничения и перспективы развития

Текущие ограничения. Модель обучена на снимках из Китая; сорта и условия Акмолинской области могут отличаться. Ячмень и корневые гнили (заявлены в заявке) пока не поддерживаются: для них нет открытых полевых данных под классификацию.

План развития:

1. **Весна–лето 2027:** сбор и разметка собственных фото с опытных полей университета (Акмолинская область) и дообучение модели; кнопка «не согласен с диагнозом» для пополнения датасета.
2. **Этап 2:** ячмень, корневые гнили, оценка степени поражения по шкале ВИЗР; работа модели на телефоне без интернета (ONNX Runtime Mobile).
3. **Этап 3:** агрегированная аналитика очагов по районам и неделям для фитосанитарных служб, рассылка предупреждений подписчикам района.

Дрон-модуль (этап 2). Для крупных хозяйств фото с телефона недостаточно. Предлагается двухпроходная съёмка дроном с RGB- или мультиспектральной камерой: обзорный полёт на высоте 100 м «змейкой» (перекрытие 70 %, ~2,8 см/пиксель) строит ортофотоплан и индекс VARI = (G−R)/(G+R−B), по которому выделяются подозрительные зоны; затем дрон снижается до 25 м (~0,7 см/пиксель) только над этими зонами, и классификатор EginAI определяет болезнь и степень поражения. По снимкам 25 м детектор колосьев (открытый датасет Global Wheat Head) оценивает густоту колоса.

Таблица 6 — Расчёт эффекта дрон-модуля (допущения: цена зерна 90 000 ₸/т, обработка 10 000 ₸/га; код и тесты — drone/calc.py)

Показатель (пример: поле 500 га)	**Расчёт и значение**
Урожайность	300 колос/м² × 22 зерна × 32 г / 1000 = 211 г/м² = 21,1 ц/га; 1056 т
Очаги болезни	6 % площади = 30 га
Потери без обработки	30 га × 2,11 т/га × 15 % = 9,5 т ≈ 855 тыс. ₸
Точечное опрыскивание	30 га + 50 % буфер = 45 га вместо 500 га
Экономия фунгицида	(500 − 45) × 10 000 ₸ = 4,55 млн ₸ (91 %)
Время съёмки	обзор 100 м: ~3,7 ч (6 батарей); уточнение 25 м: ~1,8 ч

Ограничение: классификатор обучен на снимках листьев с земли; для высоты 25 м его нужно дообучить на аэроснимках. Это включено в план этапа 2.

Коммерциализация. Для фермеров сервис остаётся бесплатным. Источники дохода: подписка для агрохолдингов и консультантов (выгрузка случаев, отчёты по полям), лицензия аналитики очагов для акиматов и фитосанитарных служб, партнёрство с дистрибьюторами средств защиты растений при сохранении нейтральности рекомендаций, гранты на цифровизацию АПК.

10. Команда и распределение работ

Таблица 5 — Команда

Участник	Роль и вклад
Әбдімүтәлі Бекназар	Капитан, руководитель проекта: архитектура, интеграция, база знаний, презентация и защита
Әбдіқадыр Ернұр	ML-инженер: подготовка датасета, обучение и оценка нейросети, экспорт в ONNX
Есен Арман	Backend: API, база данных, Telegram-бот, Docker
Жақсығұл Рамазан	Frontend и UI/UX: веб-приложение, карта, сбор и разметка фотографий

Научный руководитель — Таберхан Роман.

Список источников

1. FAO. International Year of Plant Health 2020: up to 40 % of food crops are lost to plant pests and diseases. — URL: https://www.fao.org/plant-health-2020/
2. Агроэкологический атлас России и сопредельных стран: болезни растений. — ВИЗР. — URL: https://www.agroatlas.ru/ru/content/diseases/
3. CIMMYT. Wheat diseases: rusts, septoria, Fusarium head blight. — URL: https://www.cimmyt.org/
4. Анализ аналогов и отзывов пользователей Plantix, Agrio, Farmonaut (77 отзывов, 12.11.2026). — Репозиторий EginAI, папка replica/.
5. Zhou B., Khosla A., Lapedriza A., Oliva A., Torralba A. Learning Deep Features for Discriminative Localization // CVPR. — 2016.
6. Qian J., Dai C., Ji Z., Liu J. GDFC-YOLO: An Efficient Perception Detection Model for Precise Wheat Disease Recognition // Agriculture. — 2025. — Vol. 15(14). — 1526. Датасет: https://huggingface.co/datasets/Project-AgML/wheat_disease_detection (CC-BY-4.0).
7. Tan M., Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks // ICML. — 2019.
8. Wightman R. PyTorch Image Models (timm). — URL: https://github.com/huggingface/pytorch-image-models
9. Robertson S., Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond // Foundations and Trends in IR. — 2009.
10. Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // NeurIPS. — 2020.
11. Закон Республики Казахстан от 21 мая 2013 года № 94-V «О персональных данных и их защите».

Ссылка на код и демо: https://github.com/raissov01/eginai — запуск: docker compose up, затем http://localhost:8000.